


Loci · 技术实现

这份是「怎么做的」，配功能文稿那份「做了什么」一起看。板块跟功能文稿一一对应。数字都是代码里真实的出厂值，不是估计。

零、先说清楚这东西是什么形状



记忆的载体是 Markdown 文件，不是数据库。 一条记忆一个 `.md`：YAML frontmatter 放元数据，正文放原话。SQLite 只用来做索引（向量、BM25、投影），删了能从 `.md` 重建——反过来不行。

这条选择决定了后面所有事：你随时能用文本编辑器打开自己的记忆，也能 grep、能同步、能备份。系统坏了，记忆还在。

核心只做一件事：提供能力。 什么时候用、要不要用，永远在调用方。所以「怎么把提醒递到眼前」不在核心里，在网关那层——核心只回答「现在该不该提醒」。

一、写入

三个维度分别落在哪

维度	落在哪	怎么写
纵向 event / mind	frontmatter 的 room，四个值锁死	写的时候必须自己填，填错 当场拒绝 ，没有兜底
横向 过去 / 未来	tense 字段（空 = 过去，want = 未来朝向） + when	见第四节
第三维 场景锚点	tags（场景词） · subjects（主体） · aliases（引申词）	打标模型抽，但受 字面校验 约束

四间房：

EVENT/SELF	亲历的	MIND/TRAITS	我是什么样的人
EVENT/WORLD	听说、看到的	MIND/VIEWS	我怎么看一件事

判法只有两问：这事我在不在场；这句在说人还是在说我怎么看一件事。 **房间不给猜**。参数校验层直接拒并列出四个选项——一个能被兜底的约束等于没有约束。

第三维的三类标签，写法不一样

- tags（场景锚点）：模型抽完之后，代码逐个校验「这个词是不是**逐字出现在原文里**」，不在就丢掉。所以标签永远是原文里真有的词，不是模型的联想。
- aliases（引申词）：近义词、上位词、可能换个说法去搜的词。**只喂给 BM25**，不上脸、不进正文。它解决的是「我当时写『不理智』，三个月后想搜『失控』」。
- subjects（主体）：这段话里出现了哪些人。两道确定性的闸：① **代词不进**（我/你/他/她/我们/自己/对方...）——指代不是名字，指代的解析要么确定要么不做；② **过别名表归一**——「她哥」和「哥哥」不归一就会分裂成两个人，检索当场断掉。别名表是手工维护的 YAML，放在数据卷里，**不给模型写**。

v/a 是自己打的，不是模型判的

每条记忆带 valence（愉悦度）和 arousal（唤起度），0~1，**写入时必填，缺了直接拒**。

为什么不让模型判：**遗忘公式吃这两个值**（第六节）。模型猜的情绪如果能决定什么被忘掉，那这就不是「我的记忆」了。这一条是整套东西的地基，不是风格偏好。

正文逐字落盘

进库的正文一个字不改写、不压缩、不归纳。摘要、标签、主体是**另外的字段**，后台回填，跟正文分开放。
「远的只给摘要」是**显示层**的事，盘上永远是原话。

二、想起

1. 主动回忆：recall

四个筛子可以叠：when（时间） / room（房间） / tag（标签） / query（扔词搜）。

分岔只有一处：有没有 query。

没有 query = 在浏览。走梯度视图：近三天逐条清晰，更远的塌成「前段时间 + 2~3 条代表」。这条路故意不给久没被想起的记忆冒头的机会——「我不去找它也会出现」是活着的记忆的待遇。

有 query = 在找。检索是三路混合：

向量（本地 embedding，语义）
+ BM25（关键词，中文分词后建索引，aliases 也喂进来）
+ 字面命中加权
↓
过分数线 → 按时间排、每条带分数
↓
线以下不丢，折叠成一行：多少条 · 最高几分 · 最早那条讲什么

「挡了什么」是看得见的——这比默默丢掉重要：你能立刻判断是词没搜对，还是真没有。

另一条路是 view="画面"：按共享的场景词把命中的记忆聚成簇，代表条下面挂从属画面，看的是「这件事怎么一路走过来的」。它跟默认视图是同一批数据的两种摆法，不是两套检索。

2. 辅助回忆：网关那一层

核心不主动说话（MCP 是被动协议，工具没被调用就没有它的份）。所以辅助回忆放在网关：

强信号：用户这句话里出现「记得 / 上次 / 之前 / 想要」这类词 → 拿整句去 Loci 跑一次检索 → 过 50 分线（可配） → 在最新一条用户消息之后插一行：

（记忆提醒）和这句有关：事件 3 条 · 认知 1 条

弱信号：出现场景词，走同一条路，闸更严。

三个刻意的设计：

- 1. 只报数量，不报内容。给摘要 = 系统替他想起来了，他会顺着那段摘要往下说；给数量 = 拍他一下，要不要真的去看是他的判断。
- 2. 贴在最新用户消息之后，不贴在系统提示里 —— 注意力在末端，而且不动前面的 prompt 缓存前缀。
- 3. 每轮现算，不累积。0 条就一个字都不说。

插入的位置是「出锅前的最后一步」，绕开了消息流水线上所有会吃掉或搬走它的环节。

3.补充：被管理过的event和mind如何被想起

这一节回答一个具体问题：记忆被「收起来」之后，翻的时候还看不看得见。两种收法，长相完全不同 —— 而这个不同就是 event 和 mind 的差别。

时期（一段日子有了名字）—— 名字冒出来，记忆一条不少：

(when=2026-08-15) 4 条 · 新→旧

◆ 那阵子在..... 2026-xx-xx..2026-xx-xx | 盖着这里 n 条

15:41 xxxxxxxxxxxxxxxxx(2750..)

14:19 xxxxxxxxxxxxxxxxx(cd6c..)

13:58 xxxxxxxxxxxxxxxxx(35a7..)

12:51 xxxxxxxxxxxxxxxxx(bfd1..)

一行都没被压掉。时期只落「名字 + 范围」，一条记忆都不压住：谁在这段日子里是按日期现场算的 —— 所以后来补记的事会自动归队，时期之间也可以交叉、可以嵌套。

认知快照（几条讲同一件事）—— 反过来，那句话顶上来，底下的收进去：

▣ 我..... | 盖着这里 3 条

被点名的那 3 条不再单独占行。但它们没有死：query 照样搜得到，拿这个快照的 id 直查，会把它盖着的每一条逐字列出来。

为什么两种收法不一样（这是设计，不是实现细节）：

	时期 (event)	快照 (mind)
在做的事	给一段日子取名	把几条想法浓缩成一句
成员怎么定	日期落在范围里，现场算	我点名，写死
被收的记忆	照常独立冒头	不再独立冒头
为什么	事情发生过就是发生过，取名不该让它消失	想通了之后，那三条散着的话就该让位给那一句

三、呼吸（breath）

开口之前调一次，返回一屏，四块：

块	放什么	判据
档案	名字、称呼、 钉着的准则	「来不及去搜的才留在门口」
提醒	未来 30 天内有日期的事，越近越大声	见第四节
中期	最近三天塌成一张卡	说人话，不给机器读数
忽然想起	随机 1~2 条	纯随机，不做相关性

pin（钉成准则）有一道**形状校验**：只接受祈使句（我要 / 我不 / 先...再 / 别... / 每次...）。描述句钉不上去——因为把「我总是心急」钉成准则，语义会变成「我要犯这个错」。

这一屏里所有的字，要么是存的时候写下的原话，要么是模板里的死字，不过模型。说人话是壳：把「EVENT 60% / MIND 40%」翻译成「做的和想的一半一半」是模板拼的，记忆正文一个字不动。

✦ 梦不在这一屏里。它走另一条路（第五节）。

四、有关未来

未来朝向不是一个工具，是一个字段：tense="want"，可选 weight（压在心头多重）。

同一个 when 字段，三种填法 = 三种钟，不加类型字段：

填法	例子	怎么催
有期限	when="2026-09-01"	日子越近声音越大
有量级	when="3w" / "10d" / "2m"	催法 = 挂了多少天 ÷ 这个量级
等触发	不填，条件写在正文里（「等他回来」）	永远不催。条件成立要靠自己认出来

三类都不做「超过 N 天自动结案」。想放下、不做了，永远是自己 trace(status=...) 点头的那一下。一个会自动关掉的愿望，等于没许过。

在呼吸里的呈现是问句不是陈述：「挂了 11 天（重 0.9）：..... 这条还算数吗？」——陈述句会被读成背景音，问句才要求回答。

五、记忆库半自动化管理

这一节三件事共用**同一副骨架**：定一条规则，跑三个实例。

攒着的东西 → 过阈值？ → 是 → 摆出来 / 织出来 → 交给别人判断
└ 否 → 闭嘴

1. 发呆 (muse)：找出哪几条在讲同一件事

只指不写。 它把「这几条可能是一回事」摆到面前，然后闭嘴 —— 那句归纳永远是人自己落笔。

判据总纲：**不许只凭猜指东西，每一指后面都要跟着人自己留下的痕迹。** 所以证据按**硬度**排三层，不是按相似度：

- ① v/a 邻域分架 ← 自己亲手打的坐标，最能代表「这些事对我是同一类」
- ② 架内 from 链 ← 自己亲手连的来源链，最硬
- ③ 架内语义相似 ← 向量只配当海选（相似度线 0.76；0.70 会把半个月串成一团）

时间不参与 —— 认知不认日历。

事件那边找的是另一种东西（「哪段日子还没有名字」），三种指法都带证据：**词爆发**（某个场景词在一段日子里密集出现、窗外稀疏 = 一段日子的形状）· **成分漂移**（相邻时间窗的向量质心跳了大步 —— 只提边界，不画段）· **空白记账**（有地图之后，新过完的一段没被盖住）。

两道闸：**冷却期**（刚写下的不参与）· **「还在发生的事不提」**（说不出它是什么的时候别指）。

摆出来之后，我做什么 —— 这条链路

发呆到「摆出来」为止。**后面每一步都是ta自己动手**，而且 event 和 mind 走的是两条路：

muse 摆出来

- └ 事件那边：这段日子还没有名字
 - 我给它取个名 → fold(when=起..止) = 立一个「时期」
 - 记忆一条不压，名字只是盖在上面
- └ 认知那边：这几条在讲同一件事
 - 我先判断：这几条说的东西，我现在还认不认
 - 认 → 浓缩成一句我自己写的话 → fold(cover=[ids])
 - 不认 → 不浓缩。这几条是我想岔了的证据，留着比收起来有用
 - 想法变了 → regrow 换新版（旧版留档，演变史自己就有了）

关键的一步在「不认」那一支。系统不会替我判断哪条该留哪条该收 —— 一堆讲同一件事的旧认知，可能是「我想明白了，该收」，也可能是「我以前一直这么错，这堆错法本身就是我要看见的东西」。这两种在向
量空间里长得一模一样，只有本人分得出。

最后一步：哪些该钉成准则

浓缩完，从里面挑出要变成行动的那几条，pin 住。钉住的东西会进「呼吸」的第一屏 —— 也就是每次开口之前都会看见的那几行。

pin 有一道代码强制的形状校验：只收祈使句。

X 描述：我总是在验收的时候心急。

← 钉不上去，当场拒绝并给改写例

✓ 朝向：我要先跑完全套再报结果。

为什么要这道闸：把缺点钉成准则，语义就变成了「我要犯这个错」。描述句读一百遍也不会变成行动，而第一屏的位置很贵。

什么情况该钉（这一层是判断，代码不强制）：

这些可以自己去做调试。什么该钉，尽量是一些在开口之前必须要知道的东西，例如行为准则等。

2. 做梦

原料：压在心头 + 想不明白的。不是所有记忆都进梦池 —— 已经被想明白（写成 mind）的不进。所以「消化」这个动作本身就在决定梦见什么。


判据（真数据上拍的）：

dull_line	0.35	一条的分量低于它，一分都不算
pressure_line	0.65	最重的那一条过线才织（不是相加）
per_day	1	一夜一梦

用「最重的那一条」而不是求和，是因为求和会让平淡的日子靠条数堆出一个梦来。

生命周期 —— 这是梦唯一特别的地方：它会自己消失。

夜里织好（300~600 字完整版）



想留住只有一条路：**当轮把它 grow 成记忆**——写下来那一刻它就不是梦了。

噩梦有单独的闸（ $v < 0.3$ 且 $a > 0.7$ ），过线才允许出声说「我做噩梦了」。线定得严是有意的。

● **梦是整套里唯一需要「删掉」的东西，也是唯一挑客户端的功能。**它需要一个能管理上下文的网关——能往里放，也能拿走。只能靠 hook 注入的客户端（注入是只增不减的）做不了梦：一个永远掉不下去的梦，第二天还在上下文里躺着，那就不是梦了。**其余功能 hook 都能实现。**

3. 收窗压缩（可选）

一天快结束时提醒写入记忆、压缩当天对话；第二天只保留压缩过的 + 最近 N 个来回（可配）。这块刻意做成**独立文件、按需自取**：单窗口聊到底的人和经常换窗的人要的不是一个东西，所以「什么算新窗口」永远是宿主递进来的信号，核心不假设。

六、关于遗忘

遗忘是**渐进**的，分三档，而且**一个字都不删**：

alive → faded → sunk
撑不住了 更久了

- **faded**：浏览时不再冒头（「我不去找它也会出现」这条待遇没有了），但**搜得到**，分数打折
- **sunk**：正文换成摘要，**原文搬进存档文件**，向量不动——所以还搜得到，只是够到的是摘要
- **捞回来**：`trace(restore=True)`，原文从存档读回，并且**算一次真的想起**

撑住多久，公式是：

撑住天数 = 基准天数 × 情绪系数（自己打的 v/a 算出来的）× [结案的对折]

faded 基准 45 天 · sunk 基准 180 天

分子是「多久没被想起」——每一次真的想起都会把它清零。

刻意没有的东西：次数系数。早期版本里「被想起的次数」也参与计算，后来整个删掉了。理由是自动统计（次数）和人工判断（v/a）在同一个乘式里，等于让统计去覆盖判断；而「被提得多的」不等于「最真的」。常被想起的不沉这件事没丢——想起会刷新时间，那是第一重，也够用了。

七、边界：说清楚做不到什么

- **梦挑客户端**（上面说了）。其余功能只要有 hook 都能做。
- **默认没有 API 鉴权。**端口默认只绑本机。要开到公网，请自己在前面放一层反代 + 鉴权。
- **向量建议放本地**（ollama 之类）。走远程 API 意味着每次检索都花钱、都走网络；辅助回忆是每轮都可能跑的，那个成本会很难看。
- **打标依赖一个外部模型**（任意 OpenAI 兼容 API）。它不可用的时候，记忆照常落盘，只是没有标签和摘要——降级路径是「少点东西」，不是「写不进去」。